

# Cálculo de Probabilidades

## Espacios de probabilidad

**DFN 1** (Espacio de probabilidad). *Un espacio muestral es la terna  $(\Omega, \mathcal{F}, \mathbb{P})$  donde*

- $\Omega$  es el espacio muestral. Un conjunto no-vacío
- $\mathcal{F}$  es la  $\sigma$ -álgebra, una colección de subconjuntos de  $\Omega$  que contiene a  $\Omega, \emptyset$  y es cerrada bajo complementos, e intersecciones contables.
- Una medida  $\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$  con  $\mathbb{P}(\emptyset) = 0$  y  $\mathbb{P}(\Omega) = 1$ , tal que  $\mathbb{P}$  es  $\sigma$ -aditiva.

**Teorema 1** (Propiedades de  $\mathbb{P}$ ): Si  $\mathbb{P}$  es una medida de probabilidad válida se cumple:

1.  $\mathbb{P}(A) \geq 0 \quad \forall A \in \mathcal{F}$ .
2.  $\mathbb{P}(\Omega) = 1$ .
3. Si  $A_1, A_2, \dots \in \mathcal{F}$  con  $A_i \cap A_j = \emptyset \quad \forall i \neq j$ , entonces  $\mathbb{P}(\bigcup_i A_i) = \sum_i \mathbb{P}(A_i)$ .

Las propiedades 1 a 3 se conocen como los axiomas de Kolmogorov.

4. Para cualquier  $A \in \mathcal{F}$ ,  $\mathbb{P}(A) = 1 - \mathbb{P}(A^c)$ .
5. Si  $A \subseteq B$  con  $A, B \in \mathcal{F} \implies \mathbb{P}(B \setminus A) = \mathbb{P}(B) - \mathbb{P}(A)$ .
6. Si  $A \subseteq B$  con  $A, B \in \mathcal{F} \implies \mathbb{P}(A) \leq \mathbb{P}(B)$ . Conocida como monotonidad.
7. Para cualesquiera  $A_1, A_2 \in \mathcal{F}$  se cumple  $\mathbb{P}(A_1 \cup A_2) = \mathbb{P}(A_1) + \mathbb{P}(A_2) - \mathbb{P}(A_1 \cap A_2)$ . Conocido como inclusión exclusión.
8. Para cualquier familia  $\{A_i\}_{i \in I} \in \mathcal{F}$  se cumple que  $\mathbb{P}(\bigcup_i A_i) \leq \sum_i \mathbb{P}(A_i)$ . Conocida como la desigualdad de Boole.

## Probabilidad condicional

El concepto de probabilidad condicional surge como una manera de medir probabilidades una vez que se ha reducido el espacio muestral.

**DFN 2** (Probabilidad Condicional). Sea  $(\Omega, \mathcal{F}, \mathbb{P})$  un espacio de probabilidad y sean  $A, B \in \mathcal{F}$  tal que  $\mathbb{P}(B) > 0$ . Entonces definimos

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

**Teorema 2:** Sea  $(\Omega, \mathcal{F}, \mathbb{P})$  un espacio de probabilidad. Sea  $B \in \mathcal{F}$  tal que  $\mathbb{P}(B) > 0$ . Sea  $\mathbb{Q} : \mathcal{F} \rightarrow [0, 1]$  definida como  $\mathbb{Q}(A) := \mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$ . Entonces  $\mathbb{Q}$  es una medida válida de probabilidad sobre  $(\Omega, \mathcal{F})$ .

**Teorema 3** (Probabilidad Total): Sea  $(\Omega, \mathcal{F}, \mathbb{P})$  un espacio de probabilidad. Sea  $B_1, B_2, \dots, B_n \in \mathcal{F}$  una partición de  $\Omega$ . Entonces, para cualquier  $A \in \mathcal{F}$ , se satisface

$$\mathbb{P}(A) = \sum_{i=1}^n \mathbb{P}(A|B_i) \cdot \mathbb{P}(B_i).$$

**Teorema 4** (Teorema de Bayes): Sea  $(\Omega, \mathcal{F}, \mathbb{P})$  un espacio de probabilidad. Sea  $B_1, B_2, \dots, B_n \in \mathcal{F}$  una partición de  $\Omega$ . Sea  $A \in \mathcal{F}$  tal que  $\mathbb{P}(A) > 0$ . Entonces

$$\mathbb{P}(B_k|A) = \frac{\mathbb{P}(A|B_k) \cdot \mathbb{P}(B_k)}{\sum_{i=1}^n \mathbb{P}(A|B_i) \cdot \mathbb{P}(B_i)}.$$

**DFN 3** (Eventos Independientes). Decimos que dos eventos  $A, B \in \mathcal{F}$  son independientes si y solamente si  $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$ . En dado caso, denotamos que  $A$  y  $B$  son independientes como  $A \perp B$ .

**Obs:** La independencia de eventos es un caso muy particular. No se puede asumir que es la norma.

**Teorema 5:** Supongamos  $A \perp B$  ( $A, B \in \mathcal{F}$ ). Entonces se cumplen

- a)  $A^c \perp B$ .
- b)  $A^c \perp B^c$ .
- c)  $A \perp B^c$ .

## Probabilidad condicional

**Teorema 6** (Regla de la multiplicación): Sean  $A_1, A_2, \dots, A_n \in \mathcal{F}$  cualesquiera tales que  $\mathbb{P}(A_1 \cap A_2 \cap \dots \cap A_n) > 0$ . Entonces

$$\mathbb{P}(\cap_{i=1}^n A_i) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2|A_1) \cdot \mathbb{P}(A_3|A_1 \cap A_2) \cdots \mathbb{P}(A_n | \cap_{i=1}^{n-1} A_i).$$

## Variables Aleatorias

**DFN 4** (Variable Aleatoria). Sea  $(\Omega, \mathcal{F}, \mathbb{P})$  un espacio de probabilidad. Se dice que  $X : \Omega \rightarrow \mathbb{R}$  es una variable aleatoria (v.a) sobre el espacio si y solamente si

$$X^{-1}((-\infty, x]) = \{\omega \in \Omega \mid X(\omega) \leq x\} \in \mathcal{F}.$$

La definición garantiza la permanencia en conjuntos medibles.

Las Variables Aleatorias se pueden clasificar en continuas o discretas.

**DFN 5** (Función de densidad de probabilidades). Asociada a toda v.a existe una función  $f_X : \mathbb{R} \rightarrow [0, 1]$  llamada función de densidad de probabilidades (f.d.p) dada por

$$f_X(x) := \mathbb{P}[\{\omega \in \Omega \mid X(\omega) = x\}].$$

Como azucar sintáctica podemos escribir lo anterior como

$$\mathbb{P}[\{\omega \in \Omega \mid X(\omega) = x\}] \stackrel{\text{not.}}{=} \mathbb{P}[X = x].$$

**Obs:** Con el símbolo  $\stackrel{\text{not.}}{=}$  señalamos que es una notación convencional, no una igualdad en el sentido riguroso.

**DFN 6** (Soporte de la f.d.p). El conjunto  $S \subseteq \mathbb{R}$  formado por los puntos con probabilidad no-cero es llamado el soporte de la función de densidad de probabilidades.

## Variables Aleatorias

**Teorema 7** (Propiedades de  $f_X$ ): Sea  $f_X$  la f.d.p de  $X$  una variable aleatoria. Entonces

1.  $f_X(x) \geq 0 \quad x \in \mathbb{R}$ .
2. (a) En el caso discreto:  $\sum_{x \in \mathbb{R}} f_X(x) = 1$   
(b) En el caso continuo:  $\int_{\mathbb{R}} f_X(x) = 1$ .

**DFN 7** (Función de distribución acumulada). Asociada a toda v.a se define una función  $F_X : \mathbb{R} \rightarrow [0, 1]$  llamada función de distribución acumulada (f.d.a) dada por

$$F_X(x) := \mathbb{P}[\{\omega \in \Omega \mid X(\omega) \leq x\}].$$

Una vez más, abreviamos como

$$F_X(x) := \mathbb{P}[\{\omega \in \Omega \mid X(\omega) \leq x\}] \stackrel{\text{not.}}{=} \mathbb{P}[X \leq x].$$

**Obs:** Vemos que

- $F_X(x) = \sum_{t \leq x} f_X(t)$ . En el caso discreto.
- $F_X(x) = \int_{-\infty}^x f_X(t) dt$ . En el caso continuo.

**Teorema 8** (Propiedades de  $F_X$ ): Sea  $F_X$  la f.d.a de una variable aleatoria. Entonces

1.  $F_X$  es monótona no-decreciente.
2.  $F_X$  es continua con la derecha.
3.  $\lim_{x \rightarrow -\infty} F_X(x) = 0$  &  $\lim_{x \rightarrow \infty} F_X(x) = 1$ .

## Características de una Variable Aleatoria

Estudiamos otras funciones asociadas a una v.a.

**DFN 8** (Función de supervivencia). Se define la función de supervivencia de una v.a  $X$  como

$$S_X(x) := \mathbb{P}[\omega \in \Omega \mid X(\omega) > x].$$

**Teorema 9** (Propiedades de  $S_X$ ): La función de supervivencia  $S_X$  cumple

1.  $S_X$  es monótona no-creciente.
2.  $S_X$  es continua por la derecha.
3.  $S_X(0) = 1$  &  $\lim_{t \rightarrow \infty} S_X(t) = 0$ .

## Características de una Variable Aleatoria

**DFN 9** (Función de riesgo). Si  $X$  es una variable aleatoria que modela el tiempo de falla de algún componente, definimos la función o tasa de riesgo como

$$h_X(x) = \frac{f_X(x)}{S_X(x)}.$$

Mostramos las definiciones únicamente para el caso continuo por brevedad.

**DFN 10** (Esperanza). Sea  $X$  una v.a con f.d.f  $f_X(x)$ . Supongamos que  $\sum_x |x| \cdot f_X(x)$  está acotada (en el caso discreto, la integral). Entonces, se define la esperanza de  $X$  como

$$\mathbb{E}[X] = \int_{\mathbb{R}} x \cdot f_X(x) dx$$

**Teorema 10** (Ley del estadístico inconsciente): Sea  $X$  una variable aleatoria continua, y  $g : \mathbb{R} \rightarrow \mathbb{R}$  una función. Entonces

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}} g(x) \cdot f_X(x) dx$$

**DFN 11** (Varianza). Sea  $X$  una variable aleatoria con media  $\mu$ . Entonces se define la varianza de  $X$  como

$$\text{Var}(X) = \mathbb{E}[(X - \mu)^2].$$

**Teorema 11:**  $\text{Var}(X) = \mathbb{E}[X^2] - \mu^2$ .

**DFN 12** ( $k$ -ésimo momento de  $X$ ). Definimos el  $k$ -ésimo momento de la variable aleatoria  $X$  como

$$\mathbb{E}[X^k] = \int_{\mathbb{R}} x^k \cdot f_X(x) dx$$

**DFN 13** ( $k$ -ésimo centrado momento de  $X$ ). Definimos el  $k$ -ésimo momento de la variable aleatoria  $X$  como

$$\mathbb{E}[(X - \mu)^k] = \int_{\mathbb{R}} (x - \mu)^k f_X(x) dx$$

**Teorema 12** (Linealidad): Se cumple

1.  $\mathbb{E}[aX + b] = a\mathbb{E}[X] + b$ ,
2.  $\text{Var}(aX + b) = a^2 \text{Var}(X)$ .

## Características de una Variable Aleatoria

**DFN 14** (Función generadora de momentos). Definimos la función generadora de momentos de la variable aleatoria  $X$  como

$$M_X(t) = \mathbb{E}[e^{tX}]$$

**Teorema 13:** Sea  $X$  una v.a y sea  $M_X$  su función generadora de momentos. Entonces

$$\left. \frac{d^k}{dt^k} M_X(t) \right|_{t=0} = \mathbb{E}[x^k]$$

**DFN 15** (Coeficiente de Asimetría). Se define el coef. de asimetría  $\nu_3(X)$  como:

$$\nu_3(X) = \frac{\mathbb{E}[(X - \mu)^3]}{\mathbb{E}[(X - \mu)^2]^{3/2}}.$$

**DFN 16** (Coeficiente de Kurtosis). Se define el coef. de kurtosis  $\nu_4(X)$  como:

$$\nu_4(X) = \frac{\mathbb{E}[(X - \mu)^4]}{\mathbb{E}[(X - \mu)^2]^2}.$$

### Distribución Uniforme Discreta

Decimos que una v.a  $X$  se distribuye uniforme discreta ( $X \sim \text{unif}\{x_1, \dots, x_n\}$ ) si la probabilidad de que  $X$  tome cualquiera de los valores en  $\{x_1, \dots, x_n\}$  es constante e igual a  $1/n$ .

Su f.d.p es

$$f_X(x) = \frac{1}{n} \mathbb{1}_{\{x_1, \dots, x_n\}}(x)$$

su f.d.a es

$$F_X(x) = \begin{cases} 0 & \text{si } x < 1, \\ \frac{1}{n} & \text{si } 1 \leq x < 2, \\ \frac{2}{n} & \text{si } 2 \leq x < 3, \\ \vdots & \\ \frac{n}{n} & \text{si } x \geq n. \end{cases}$$

Características:

$$\mathbb{E}[X] = \frac{1}{n} \sum_{i=1}^n x_i = \mu$$

$$\text{Var}[X] = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

$$M_X(t) = \frac{e^t(1 - e^{nt})}{n(1 - e^t)}.$$

### Distribución Bernoulli

Decimos que  $X$  se distribuye Bernoulli ( $X \sim \text{Ber}(p)$ ) si modela un experimento con dos resultados: éxito y fracaso con probabilidad  $p$  y  $1 - p$  respectivamente.

Su f.d.p es

$$f_X(x) = p^x(1 - p)^{1-x} \mathbb{1}_{\{0,1\}}(x)$$

su f.d.a es

$$F_X(x) = \begin{cases} 0 & \text{si } x < 0, \\ 1 - p & \text{si } 0 \leq x < 1, \\ 1 & \text{si } x \geq 1. \end{cases}$$

Características:

$$\mathbb{E}[X] = p$$

$$\text{Var}[X] = p(1 - p)$$

$$M_X(t) = (1 - p)pe^t.$$

### Distribución binomial

Decimos que  $X$  se distribuye binomial ( $X \sim \text{bin}(n, p)$ ) si modela una serie de  $n$  ensayos independientes Bernoulli.

Su f.d.p es

$$f_X(x) = \binom{n}{x} p^x (1 - p)^{n-x} \mathbb{1}_{\{0,1,\dots,n\}}(x)$$

su f.d.a no tiene una expresión reducida.

Características:

$$\mathbb{E}[X] = np$$

$$\text{Var}[X] = np(1 - p)$$

$$M_X(t) = (pe^t + (1 - p))^n.$$

### Distribución Geométrica

Decimos que  $X$  se distribuye binomial ( $X \sim \text{geo}(p)$ ) si modela una sucesión infinita ensayos independientes Bernoulli.

Su f.d.p es

$$f_X(x) = p(1 - p)^{x-1} \mathbb{1}_{\{0,1,\dots\}}(x)$$

su f.d.a es

$$F_X(x) = \sum_{u \leq x} f_X(u) \begin{cases} 0 & \text{si } x < 0, \\ 1 - (1 - p)^{k+1} & \text{si } k \leq x < k + 1. \end{cases}$$

Características:

$$\mathbb{E}[X] = \frac{1 - p}{p}$$

$$\text{Var}[X] = \frac{1 - p}{p^2}$$

$$M_X(t) = \frac{p}{1 - (1 - p)e^t}.$$

### Distribución Binomial Negativa

Decimos que  $X$  se distribuye binomial negativa ( $X \sim \text{bin neg}(r, p)$ ) si modela el número de fracasos antes de obtener el  $r$ -ésimo éxito en una infinitos ensayos Bernoulli.

$$f_X(x) = \binom{r+x-1}{x} p^r (1 - p)^x \mathbb{1}_{\{0,1,\dots\}}(x)$$

### Distribución Binomial Negativa

Su f.d.a no tiene expresión reducida.

Características:

$$\mathbb{E}[X] = \frac{r(1 - p)}{p}$$

$$\text{Var}[X] = \frac{r(1 - p)}{p^2}$$

$$M_X(t) = \frac{p^r}{[1 - (1 - p)e^t]^r}$$

### Distribución Hipergeométrica

Esta distribución modela la probabilidad de obtener un número particular de objetos en una muestra de tamaño  $n$  de  $N$  totales, con  $K$  de interés. Escribimos  $X \sim \text{hipergeo}(N, K, n)$ .

Su f.d.p es

$$f_X(x) = \frac{\binom{K}{x} \binom{N-K}{n-x}}{\binom{N}{n}} \mathbb{1}_{\{0,1,\dots\}}(x)$$

Su f.d.a no tiene expresión reducida.

Sus primeros dos momentos son

$$\mathbb{E}[X] = n \frac{K}{N},$$

$$\text{Var}[X] = n \frac{K}{N} \frac{N - K}{N} \frac{N - n}{N - 1}.$$

### Distribución Poisson

Modela la el número de eventos que ocurren dentro de un intervalo de tiempo dado, conociendo la tasa media de ocurrencia  $\lambda$ . Escribimos  $X \sim \text{Po}(\lambda)$

Su f.d.p es

$$f_X(x) = e^{-\lambda} \frac{\lambda^x}{x!} \mathbb{1}_{\{0,1,\dots\}}(x)$$

Características:

$$\mathbb{E}[X] = \lambda$$

$$\text{Var}[X] = \lambda$$

$$M_X(t) = e^{\lambda(e^t - 1)}.$$

**Obs:** Se puede aproximar una v.a  $X \sim \text{bin}(n, p)$  mediante otra  $Y \sim \text{Po}(\lambda)$  con  $\lambda = np$ .

### Distribución Uniforme Continúa

Esta distribución modela un espacio equiprobable en el intervalo  $(a, b)$ . Escribimos  $X \sim \text{unif}(a, b)$ .

Su f.d.p es

$$f_X(x) = \frac{1}{b-a} \mathbb{1}_{(a,b)}(x)$$

Su f.d.a es

$$F_X(x) = \begin{cases} 0 & \text{si } x \leq a, \\ \frac{x-a}{b-a} & \text{si } a < x < b, \\ 1 & \text{si } x \geq b. \end{cases}$$

Características:

$$\begin{aligned} \mathbb{E}[X] &= \frac{a+b}{2} \\ \text{Var}[X] &= \frac{(b-a)^2}{12} \\ M_X(t) &= \frac{e^{tb} - e^{ta}}{t(b-a)}. \end{aligned}$$

### Distribución Exponencial

Decimos  $X \sim \exp(\lambda)$  con  $\lambda > 0$ . Puede pensarse como la versión continua de la distribución Poisson.

Su f.d.p es

$$f_X(x) = \lambda e^{-\lambda x} \mathbb{1}_{(0,\infty)}(x)$$

Su f.d.a es

$$F_X(x) = 1 - e^{-\lambda x} \mathbb{1}_{(0,\infty)}(x)$$

Características:

$$\begin{aligned} \mathbb{E}[X] &= \frac{1}{\lambda} \\ \text{Var}[X] &= \frac{1}{\lambda^2} \\ M_X(t) &= \frac{\lambda}{\lambda - t}. \end{aligned}$$

### Distribución Gamma

Decimos  $X \sim \text{gamma}(\alpha, \lambda)$  con  $\alpha > 0, \lambda > 0$ .

Su f.d.p es

$$f_X(x) = \frac{(\lambda x)^{\alpha-1}}{\Gamma(\alpha)} \mathbb{1}_{(0,\infty)}(x)$$

con

$$\Gamma(\alpha) = \int_0^\infty x^{\alpha-1} e^{-x} dx$$

la función Gamma.

Su f.d.a no tiene expresión compacta.

Características:

$$\begin{aligned} \mathbb{E}[X] &= \frac{\alpha}{\lambda} \\ \text{Var}[X] &= \frac{\alpha}{\lambda^2} \\ M_X(t) &= \left( \frac{\lambda}{\lambda - t} \right)^\alpha. \end{aligned}$$

### Distribución Beta

Decimos  $X \sim \text{beta}(a, b)$ .

Su f.d.p es

$$f_X(x) = \frac{1}{B(a, b)} x^{a-1} \mathbb{1}_{(0,1)}(x)$$

con

$$B(a, b) = \int_0^1 t^{a-1} (1-t)^{b-1} dt$$

la función Beta.

Su f.d.a no tiene expresión compacta.

Características:

$$\begin{aligned} \mathbb{E}[X] &= \frac{a}{a+b} \\ \text{Var}[X] &= \frac{ab}{(a+b+1)(a+b)^2} \\ M_X(t) &= \sum_{k=0}^{\infty} \frac{t^k}{k!} \frac{B(\alpha+k, \beta)}{B(\alpha, \beta)} \end{aligned}$$

### Distribución Weibull

Decimos  $X \sim \text{Weibull}(\alpha, \lambda)$

Su f.d.p es

$$f_X(x) = \lambda \alpha (\lambda x)^{\alpha-1} e^{-(\lambda x)^\alpha} \mathbb{1}_{(0,\infty)}(x)$$

Su f.d.a es

$$F_X(x) = 1 - e^{-(\lambda x)^\alpha} \mathbb{1}_{(0,\infty)}(x)$$

Sus primeros dos momentos son

$$\begin{aligned} \mathbb{E}[X] &= \frac{1}{\lambda} \Gamma\left(1 + \frac{1}{\alpha}\right), \\ \text{Var}[X] &= \frac{1}{\lambda^2} \left[ \Gamma\left(1 + \frac{2}{\alpha}\right) - \Gamma^2\left(1 + \frac{1}{\alpha}\right) \right]. \end{aligned}$$

### Distribución Normal

Decimos  $X \sim N(\mu, \sigma^2)$

Su f.d.p es

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}.$$

Su f.d.a no tiene una forma compacta, y la integral que la describe no tiene forma cerrada.

Características:

$$\begin{aligned} \mathbb{E}[X] &= \mu \\ \text{Var}[X] &= \sigma^2 \\ M_X(t) &= e^{\mu t} e^{\frac{1}{2}\sigma^2 t^2}. \end{aligned}$$

Para la mayoría de los cálculos es necesario tener en cuenta lo siguiente:

Si  $X \sim N(\mu, \sigma^2)$ , entonces  $Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$ . Por lo tanto,  $\mathbb{P}[X \leq x] = \Phi\left(\frac{x-\mu}{\sigma}\right)$ .

Donde

$$\Phi(z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}u^2} du.$$

Para una normal estándar se cumple:

$$\begin{aligned} \mathbb{E}[X] &= 0 \\ \text{Var}[X] &= 1 \\ M_X(t) &= e^{\frac{1}{2}t^2}. \end{aligned}$$