

# Cálculo de Probabilidades II

## Vectores Aleatorios

Inicialmente nos concentramos en la definición para un vector aleatorio en  $\mathbb{R}^2$ , con cada variable aleatoria continua.

**DFN 1** (Función de distribución conjunta). Definimos la función de distribución conjunta (f. d. c) del vector aleatorio  $\mathbf{X} = (X_1, X_2)$  como:

$$F_{X_1, X_2} := F_{\mathbf{X}}(x_1, x_2) = \mathbb{P}(X_1 \leq x_1, X_2 \leq x_2) \\ = \mathbb{P}(\{\omega \mid X_1(\omega) \leq x_1 \cap X_2(\omega) \leq x_2\})$$

**Teorema 1** (Propiedades de  $F_{\mathbf{X}}$ ): La f. d. c cumple con las siguientes:

- $\lim_{x_1 \rightarrow -\infty} F_{X_1, X_2}(x_1, x_2) = 0$
  - $\lim_{x_2 \rightarrow -\infty} F_{X_1, X_2}(x_1, x_2) = 0$
  - $\lim_{x_1, x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2) = 1$
- Análogo a la monotonicidad no-decreciente. Si  $a_1 \leq x_1, a_2 \leq x_2$  entonces,

$$\mathbb{P}(a_1 \leq X_1 \leq b_1, a_2 \leq X_2 \leq b_2) \geq 0.$$

- Es continua por la derecha en cada argumento.

**DFN 2** (Función de distribución marginal). Sea  $(X_1, X_2)$  un vec. aleatorio con función de distribución conjunta  $F_{X_1, X_2}(x_1, x_2)$ . Entonces  $F_{X_1}(x_1)$  y  $F_{X_2}(x_2)$  son llamadas funciones de distribución marginales para  $X_1$  y  $X_2$  y se obtienen como

$$F_{X_i}(x_i) = \lim_{x_j \rightarrow \infty} F_{X_1, X_2}(x_1, x_2)$$

**DFN 3** (Función de densidad conjunta). Sea  $(X_1, X_2)$  un vec. aleatorio. Una función de densidad conjunta del vector, es una función  $f_{X_1, X_2}(x_1, x_2)$  que satisface:

- $f_{X_1, X_2}(x_1, x_2) \geq 0 \quad \forall (x_1, x_2) \in \mathbb{R}^2$ .
- $\iint_{\mathbb{R}^2} f_{X_1, X_2}(x_1, x_2) dx_1 dx_2 = 1$ .
- $F_{X_1, X_2}(x_1, x_2) = \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} f_{X_1, X_2}(u_1, u_2) du_1 du_2$

En general se pueda calcular  $\mathbb{P}(A)$  con  $A \subseteq \mathbb{R}^2$  como  $\iint_A f(x_1, x_2) dx_1 dx_2$ .

## Vectores Aleatorios

**Teorema 2:** Sea  $(X_1, X_2)$  un vector aleatorio con función de densidad conjunta  $f(x_1, x_2)$ . Entonces, las funciones de densidad marginales se pueden obtener como

$$f_{X_1}(x_1) = \int_{\mathbb{R}} f_{X_1, X_2}(x_1, x_2) dx_2.$$

## Distribuciones condicionales

**DFN 4** (Función de densidad condicional). Sea  $(X_1, X_2)$  un vec. aleatorio con funciones de distribución acumulada y conjuntas  $f_{X_1, X_2}, f_{X_1}, f_{X_2}$ . La función de densidad condicional de  $X_1$  con respecto a  $X_2$  se define como:

$$f_{X_1|X_2} := \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_2}(x_2)}$$

dado  $f_{X_2}(x_2) > 0$ .

Las funciones de distribución condicionales son funciones propias. Es decir, cumplen con las propiedades de cualquier otra función de densidad.

**Obs:** Una función de densidad condicional  $f_{X_1|X_2}$  es univariada, y su argumento es  $x_1$ . Al calcularse se debe cancelar el soporte de  $X_2$ .

**DFN 5** (Función de distribución condicional). Se define la función de distribución acumulada de  $X_1$  dado  $X_2$  como:

$$F_{X_1|X_2} := \int_{-\infty}^{x_1} f_{X_1|X_2}(u_1|x_2) du_1$$

**DFN 6** (Independencia estocástica). Sea  $(X_1, X_2)$  un vec. aleatorio. Se dice que  $X_1$  y  $X_2$  son independientes ( $X_1 \perp X_2$ ) si y solo se satisface alguno de los siguientes:

- $f_{X_1|X_2}(x_1|x_2) = f_{X_1}(x_1), \quad \text{si } f_{X_2}(x_2) > 0,$
- $f_{X_2|X_1}(x_2|x_1) = f_{X_2}(x_2), \quad \text{si } f_{X_1}(x_1) > 0,$
- $f_{X_1, X_2}(x_1, x_2) = f_{X_1}(x_1) \cdot f_{X_2}(x_2).$

**Obs:**  $A \cap B \implies A \not\perp B$ .

## Distribuciones condicionales

**Teorema 3:** Sea  $(X_1, X_2)$  un vec. aleatorio con  $f_{X_1|X_2}$  y  $f_{X_2|X_1}$ . Entonces, la función de densidad marginal de  $X_1$  es

$$f_{X_1}(x_1) = \int_{\mathbb{R}} f_{X_1|X_2}(x_1|x_2) \cdot f_{X_2}(x_2) dx_2 \quad (\Delta)$$

y

$$f_{X_1|X_2}(x_1|x_2) = \frac{f_{X_2|X_1}(x_2|x_1) \cdot f_{X_1}(x_1)}{f_{X_2}(x_2)} \quad (\square)$$

Los resultados  $\Delta$  y  $\square$  pueden ser pensados como generalizaciones del Teorema de Probabilidad Total y el Teorema de Bayes, respectivamente.

**Teorema 4:** Sea  $(X, Y)$  un vec. aleatorio. Entonces,  $X \perp Y \iff f_{X_1, X_2}(x_1, x_2) = g(x_1)\mathbb{1}_A(x) \cdot h(x_2)\mathbb{1}_B(y)$

**Obs:** El teorema anterior nos permite concluir que dos v.a's son dependientes si su función de densidad está escrita en términos de una indicadora que no se puede "factorizar" en expresiones que dependan únicamente de  $x$  y de  $y$ .

**Teorema 5:** Si  $X_1, \dots, X_n$  son v.a's independientes  $\implies g(X_1), \dots, g(X_n)$  son también v.a's independientes.

## Momentos multivariados

**DFN 7** (Esperanza de una función). Sea  $g: \mathbb{R}^k \rightarrow \mathbb{R}$  una función. Sea  $\mathbf{X}$  un vec. aleatorio  $k$ -dimensional con fn. de densidad conjunta  $f_{\mathbf{X}}(\mathbf{x})$ . Entonces,

$$\mathbb{E}[g(\mathbf{X})] := \int \dots \int_{\mathbb{R}^k} g(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}$$

**Teorema 6** (Linealidad de  $\mathbb{E}$ ): Sea  $\mathbf{X}$  un vec. a. tal que  $\mu_i = \mathbb{E}[X_i]$  existe y es finita  $\forall i = 1, \dots, k$ . Entonces

$$\mathbb{E}\left[\sum_{i=1}^k \alpha_i X_i\right] = \sum_{i=1}^k \alpha_i \mathbb{E}[X_i]$$

**DFN 8** (Covarianza). Se define la covarianza entre  $X$  y  $Y$  como:

$$\text{Cov}(X, Y) := \mathbb{E}[\{X - \mathbb{E}(X)\} \cdot \{Y - \mathbb{E}(Y)\}]$$

## Momentos multivariados

Notación:  $\text{Cov}(X, Y) = \sigma_{X,Y}$

**Obs:** Independencia estocástica  $\implies \text{Cov}(X, Y) = 0$ . Pero cuidado,  $\text{Cov}(X, Y)$  no necesariamente implica  $X \perp Y$ .

**Teorema 7:**  $\text{Cov}(X, Y) = \mathbb{E}[X \cdot Y] = \mu_X \mu_Y$ .

**Teorema 8** (Propiedades de Varianza & Covarianza): Sea  $\mathbf{X}$  un vec. a.  $k$ -dimensional,  $\alpha_i, \beta_i$  constantes, y t.q  $\mathbb{E}[X_i]$  es finita.

$$\text{a) } \text{Var} \left[ \sum_{i=1}^k \alpha_i X_i \right] = \sum_{i=1}^k \alpha_i^2 \text{Var}(X_i) + 2 \sum_{i < j} \alpha_i \alpha_j \text{Cov}(X_i, X_j)$$

$$\text{b) } \text{Cov}(\alpha_1 + \alpha_2 X_1, \beta_1 + \beta_2 X_2) = \alpha_2 \beta_2 \text{Cov}(X_1, X_2)$$

$$\text{c) } \text{Cov} \left[ \sum_{i=1}^k \alpha_i X_i, \sum_{j=1}^k \beta_j X_j \right] = \sum_{i=1}^k \sum_{j=1}^k \alpha_i \beta_j \text{Cov}(X_i, X_j)$$

**DFN 9** (Coeficiente de correlación). Sea  $\mathbf{X} = (X_1, X_2)$  un vec. a. Entonces el coeficiente de correlación entre  $X_1$  y  $X_2$  se define como:

$$\rho_{X_1, X_2} := \frac{\text{Cov}(X_1, X_2)}{\sqrt{\text{Var}(X_1) \text{Var}(X_2)}} = \frac{\sigma_{X_1, X_2}}{\sigma_{X_1} \cdot \sigma_{X_2}}$$

**Teorema 9** (Propiedades de  $\rho_{X,Y}$ ): El coef. de correlación entre  $X, Y$  cumple:

- $|\rho_{X,Y}| \leq 1$
- $|\rho_{X,Y}| = 1 \iff \exists \alpha, \beta \in \mathbb{R} \text{ tal que } \mathbb{P}(Y = \alpha + \beta X) = 1.$

**Teorema 10** (Desigualdad de Cauchy-Schwarz): Sean  $X, Y$  v.a.s con segundos momentos finitos. Entonces

$$|\mathbb{E}[X \cdot Y]|^2 \leq \mathbb{E}(X^2) \cdot \mathbb{E}(Y^2)$$

con igualdad si y solo si  $\mathbb{P}(Y = a + bX) = 1$

## Esperanza y Varianza de vectores aleatorios

**DFN 10** (Momentos conjuntos). Sea  $\mathbf{X} = (X_1, \dots, X_k)$  un vec. aleatorio. Sean  $g_1(\mathbf{X}) = X_1^{s_1} X_2^{s_2} \dots X_k^{s_k}$  y  $g_2(\mathbf{X}) = (X_1 - \mu_1)^{s_1} \dots (X_k - \mu_k)^{s_k}$ . Entonces

$$\mu'_{s_1, \dots, s_k} := \mathbb{E}[g_1(\mathbf{X})] = \mathbb{E}[X_1^{s_1} X_2^{s_2} \dots X_k^{s_k}]$$

es el momento de orden  $r = \sum_{i=1}^k s_i$  no-central, y

$$\mu_{s_1, \dots, s_k} := \mathbb{E}[g_2(\mathbf{X})] = \mathbb{E}[(X_1 - \mu_1)^{s_1} \dots (X_k - \mu_k)^{s_k}]$$

es el momento de orden  $r$  central.

**DFN 11** (Esperanza de un vector aleatorio). Sea  $\mathbf{X}^T = (X_1, \dots, X_k)$  un vec. a. Definimos

$$\mathbb{E}[\mathbf{X}] := \mathbb{E} \begin{pmatrix} X_1 \\ \vdots \\ X_n \end{pmatrix} = \begin{bmatrix} \mathbb{E}(X_1) \\ \vdots \\ \mathbb{E}(X_k) \end{bmatrix} = \begin{bmatrix} \mu_1 \\ \vdots \\ \mu_k \end{bmatrix} = \boldsymbol{\mu}$$

**DFN 12** (Varianza de un vector aleatorio).

$$\begin{aligned} \text{Var}(\mathbf{X}) &= \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^T] = \Sigma \in \mathbb{R}^{k \times k} \\ &= \begin{bmatrix} \sigma_1^2 & \sigma_{1,2} & \dots & \sigma_{1,k} \\ \sigma_{2,1} & \sigma_2^2 & \dots & \sigma_{2,k} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{k,1} & \sigma_{k,2} & \dots & \sigma_k^2 \end{bmatrix} \end{aligned}$$

A veces se define la varianza total como

$$\text{tr}(\Sigma) = \sum_{i=1}^k \sigma_i^2$$

Si  $\mathbf{Y}^T = (Y_1, \dots, Y_k)$  es otro vec. a.

$$\text{Cov}(\mathbf{X}, \mathbf{Y}) = \mathbb{E}\{(\mathbf{X} - \boldsymbol{\mu}_X)(\mathbf{Y} - \boldsymbol{\mu}_Y)\}$$

**DFN 13** (Matriz de correlación). Sea  $R = \text{Corr}(\mathbf{X})$  dada como

$$R = (\rho_{ij}) \quad i, j = 1, \dots, k$$

Si  $V_X = \text{diag}(\sigma_1^2, \dots, \sigma_k^2)$  entonces

$$R = V_X^{-1/2} \Sigma V_X^{1/2}$$

## Momentos condicionales

**DFN 14** (Esperanza condicional). Sea  $\mathbf{X}^T = (X_1, X_2)$  un vec. a. y  $g(\cdot, \cdot)$  una función con imagen subconjunto de  $\mathbb{R}$ . La esperanza condicional de  $g(X_1, X_2)$  dado  $X_2 = x_2$  se define como

$$\mathbb{E}[g(X_1, X_2) | X_2 = x_2] = \int_{\mathbb{R}} g(X_1, X_2) \cdot f_{X_1|X_2}(x_1 | x_2) dx_1$$

**Obs:** Es muy importante notar que  $\mathbb{E}[X_1 | X_2]$  es función de  $x_2$ .

**Teorema 11** (Esperanza y Varianza iterada): Sea  $(X_1, X_2)$  un vec. a. Entonces

$$\text{a) } \mathbb{E}[X_1] = \mathbb{E}_{X_2} \mathbb{E}[X_1 | X_2]$$

$$\text{b) } \text{Var}(X_1) = \mathbb{E}_{X_2} \text{Var}(X_1 | X_2) + \text{Var}_{X_2} \mathbb{E}(X_1 | X_2).$$

## Distribuciones multivariadas importantes

### Distribución multinomial

Generalización de la distribución binomial para  $k$  clases. La distribución binomial es una multinomial con  $k = 2$

Suponga que el resultado de un experimento se puede clasificar en  $k$  clases  $c_1, c_2, \dots, c_k$  con probabilidades  $p_1, \dots, p_k$  tal que  $\sum_{i=1}^k p_i = 1$ . Definimos  $X_i$  = número de los  $n$  ensayos cuyo resultado está en  $c_i$ . Entonces

$$f(x_1, \dots, x_k) = \binom{n}{x_1, \dots, x_k} \prod_{i=1}^n p_i^{x_i} \mathbb{1}_{\{\sum_{i=1}^k x_i = n\}}(\mathbf{x})$$

donde

$$\binom{n}{x_1, \dots, x_k} := \frac{n!}{x_1! \dots x_k!}$$

Denotamos  $\mathbf{X}^T \sim \text{Mult}(n, p_1, \dots, p_k)$

**Teorema 12** (Propiedades de la multinomial): Tomando  $\mathbf{X}^T = (X_1, X_2, X_3) \sim \text{Mult}(n, p_1, p_2, p_3)$

$$\text{a) } M_{\mathbf{X}}(\mathbf{t}) = (p_1 e^{t_1} + p_2 e^{t_2} + p_3)^n$$

$$\text{b) } X_i \sim \text{Bin}(n, p_i)$$

$$\text{c) } X_1 | X_2 \sim \text{Bin}\left(n - X_2, \frac{p_1}{1 - p_2}\right)$$

$$\text{d) } \text{Cov}(X_i, X_j) = -n p_i p_j$$

## Distribuciones multivariadas importantes

### Distribución Normal multivariada

Comenzando con el caso bivariado,  $\mathbf{X}^T = (X_1, X_2)$  tiene una distribución normal bivariada con media  $\boldsymbol{\mu}^T = (\mu_1, \mu_2)$ , varianzas  $\sigma_1^2, \sigma_2^2$  y correlación  $\rho$  si su función de densidad es

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left(-\frac{1}{2(1-\rho^2)}\left[\left(\frac{x_1-\mu_1}{\sigma_1}\right)^2 + \left(\frac{x_2-\mu_2}{\sigma_2}\right)^2 - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2}\right]\right)$$

con  $(x_1, x_2) \in \mathbb{R}^2, (\mu_1, \mu_2) \in \mathbb{R}^2, \sigma_1^2, \sigma_2^2 > 0, \rho \in [-1, 1]$ .

**Teorema 13** (Propiedades de la normal multivariada): Tomando el caso bivariado

a)

$$M_{X_1, X_2}(t_1, t_2) = \exp\left(t_1\mu_1 + t_2\mu_2 + \frac{1}{2}[t_1^2\sigma_1^2 + 2\rho\sigma_1\sigma_2 t_1 t_2 + t_2^2\sigma_2^2]\right)$$

b)  $X_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$

c)  $X_1 \perp X_2 \iff X_1$  y  $X_2$  son no-correlacionadas

d)

$$X_2|X_1 = x_1 \sim \mathcal{N}\left(\mu_2 + \rho\frac{\sigma_1}{\sigma_2}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2)\right)$$

**Obs:** En cualquier distribución  $X_1 \perp X_2 \implies \rho_{X_1, X_2} = 0$ , pero  $X_1, X_2$  no-correlacionados implica independencia solo se cumple en el caso de la normal.

Ahora, en el caso multivariado:

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{\exp\left[-\frac{1}{2}(\mathbf{X} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{X} - \boldsymbol{\mu})\right]}{\sqrt{(2\pi)^k |\Sigma|}}$$

Denotada  $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$  y cumple:

$$1. M_{\mathbf{X}}(\mathbf{t}) = \exp\left(\mathbf{t}^T \boldsymbol{\mu} + \frac{1}{2} \mathbf{t}^T \Sigma \mathbf{t}\right)$$

## Función característica de un vector aleatorio

**Teorema 14** (Unicidad de la función generadora de momentos): Sean  $X, Y$  dos v.a.'s con fn. de densidad  $f_X(x)$  y  $f_Y(y)$ . Sup. que  $M_X(t)$  y  $M_Y(t)$  existen y son iguales  $\forall t \in (-h, h), h > 0$ . Entonces, se cumple que  $f_X(x) = f_Y(y)$ .

**Corolario 14.1:** Para cada función generadora de momentos, existe una única función de densidad de probabilidades asociada.

A partir de ahora adoptamos la convención de abreviar función generadora de momentos como f.g.m.

**DFN 15** (Generadora de momentos multivariada). Sea  $\mathbf{X}^T = (X_1, \dots, X_n)$  un vec. aleatorio. Su f.g.m es

$$M_{\mathbf{X}}(\mathbf{t}) = \mathbb{E}\left[e^{\mathbf{t}^T \mathbf{X}}\right] = \mathbb{E}[\exp(t_1 X_1 + \dots + t_k X_k)]$$

**Teorema 15** (Propiedades de la f.g.m multivariada): Sea  $M_{\mathbf{X}}(\mathbf{t})$  la f.g.m asociada a  $\mathbf{X}^T = (X_1, \dots, X_n)$ .

$$a) \mathbb{E}[X_i^r] = \frac{\partial^r}{\partial t_i^r} M_{\mathbf{X}}(\mathbf{0})$$

$$b) \mathbb{E}[X_i^r X_j^s] = \frac{\partial^{r+s}}{\partial t_i^r \partial t_j^s} M_{\mathbf{X}}(\mathbf{0})$$

**Teorema 16:** Sean  $g_1, g_2 : \mathbb{R} \rightarrow \mathbb{R}$  funciones. Si  $X_1 \perp X_2 \implies \mathbb{E}[g_1(X_1)g_2(X_2)] = \mathbb{E}[g_1(X_1)]\mathbb{E}[g_2(X_2)]$

**Teorema 17:** Las variables aleatorias  $X_1, \dots, X_n$  son independientes  $\iff M_{\mathbf{X}}(\mathbf{t}) = \prod_{i=1}^k M_{X_i}(t_i)$

**DFN 16** (Función característica). Sea  $X$  una v.a. La función característica  $\varphi_X(t)$  para  $x$  es una función compleja de  $t$  dada como:

$$\varphi_X(t) := \mathbb{E}[e^{itX}], \quad \forall t \in \mathbb{R}$$

**Teorema 18** (Propiedades de  $\varphi_X(t)$ ): La función característica de  $X$  cumple:

a)  $\varphi_X(t)$  siempre existe  $\forall t \in \mathbb{R}$

$$b) \frac{\partial^r}{\partial t^r} \varphi_X(0) = i^r \mathbb{E}[X^r]$$

c)  $\varphi_X(t)$  es uniformemente continua

d) Si  $\varphi_X(t) = \varphi_Y(t) \implies f_X(x) = f_Y(y)$

## Función característica

**DFN 17** (Fórmula de inversión). Sea  $X$  una v.a. con función característica  $\varphi_X(t)$ . Entonces, la función de densidad está dada como:

$$f_X(x) = \begin{cases} \frac{1}{2\pi} \int_{-\pi}^{\pi} e^{-itx} \varphi_X(t) dt & \text{si } X \text{ es discreta} \\ \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-itx} \varphi_X(t) dt & \text{si } X \text{ continua} \end{cases}$$

**DFN 18** (Función característica multivariada). Sea  $\mathbf{X}^T = (X_1, \dots, X_k)$  un vec. a. Su función característica multivariada está dada como:

$$\varphi_{\mathbf{X}}(\mathbf{t}) = \mathbb{E}[e^{i\mathbf{t}^T \mathbf{X}}] \quad \forall \mathbf{t} \in \mathbb{R}$$

y cumple:

- $\frac{\partial^r}{\partial t_1^{s_1} \dots \partial t_k^{s_k}} \varphi_{\mathbf{X}}(\mathbf{0}) = i^r \cdot \mathbb{E}[X_1^{s_1} \dots X_k^{s_k}]$  con  $r = \sum s_i$
- $(X_1, \dots, X_k)$  es un vec. a. independiente si y solo si  $\varphi_{\mathbf{X}}(\mathbf{t}) = \prod_{i=1}^k \varphi_{X_i}(t_i)$ .

## Distribuciones mezcla

**DFN 19** (Distribución mezcla). Sea  $f_i(x)$  para  $i = 1, \dots, n$  un conjunto de funciones de densidad univariadas. Sea  $p_i$  con  $i = 1, \dots, n$  números no-negativos t.q  $\sum_i p_i = 1$ . Entonces

$$f_X(x) := \sum_{i=1}^n p_i f_i(x)$$

es otra función de densidad llamada distribución mezcla.

Una distribución mezcla satisface las propiedades básicas de cualquier otra distribución.

## Transformaciones de vectores aleatorios

Sean  $X_1, \dots, X_n$  v.a's y sea  $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$  una función medible. Queremos encontrar la distribución de  $Y = g(\mathbf{X})$ . Para hacerlo, hay 3 técnicas:

1. Técnica de las funciones característica y generadora de momentos
2. Técnica de la función de distribución
3. Técnica de cambio de variable

**DFN 20** (Distribución  $\chi^2$ ). Si  $X \sim \text{Ga}(k/2, k/2)$  con  $k \in \mathbb{N}$  entonces  $X \sim \chi^2_{(k)}$  con  $k$  grados de libertad. Adicionalmente si  $X \sim \chi^2_{(1)} \implies Y = \sum_{j=1}^n X_j \sim \chi^2_{(n)}$ .

**Teorema 19** (Transformación distribución o transformación integral de probabilidad): Si  $X$  es una v.a continua con fn. de distribución  $F_X(x)$ . Entonces la transformación  $Y = F_X(X)$  es una v.a unif(0, 1). De igual manera, si  $Y = \text{unif}(0, 1) \implies X = F_X^{-1}(Y)$  es una v.a con función de distribución  $F_X$ .

**Teorema 20** (Distribución de suma y resta de v.a's): Sea  $(X_1, X_2)$  un vec. a. con función de densidad conjunta  $f_{X_1, X_2}(x_1, x_2)$ . Sean  $Z = X_1 + X_2$ ,  $W = X_1 - X_2$ , entonces:

$$\begin{aligned} f_Z(z) &= \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, z - x_1) dx_1 \\ &= \int_{-\infty}^{\infty} f_{X_1, X_2}(z - x_1, x_2) dx_2 \\ f_W(w) &= \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_1 - w) dx_1 \\ &= \int_{-\infty}^{\infty} f_{X_1, X_2}(x + x_2, x_2) dx_2 \end{aligned}$$

**Teorema 21** (Distribución del producto y cociente de v.a's): Sea  $(X_1, X_2)$  un v.a continuo con densidad  $f_{X_1, X_2}(x_1, x_2)$  y sean  $Z = X_1 X_2$  y  $W = X_1 / X_2$ , entonces:

$$\begin{aligned} f_Z(z) &= \int_{-\infty}^{\infty} \frac{1}{|x_1|} f_{X_1, X_2}\left(x_1, \frac{z}{x_1}\right) dx_1 \\ &= \int_{-\infty}^{\infty} \frac{1}{|x_2|} f_{X_1, X_2}\left(\frac{z}{x_2}, x_2\right) dx_2 \end{aligned}$$

## Transformaciones de vectores aleatorios

$$f_W(w) = \int_{-\infty}^{\infty} \frac{1}{|x_2|} f_{X_1, X_2}(w \cdot x_2, x_2) dx_2$$

**DFN 21** (Distribución  $t$  de Student). Sea  $X$  una variable aleatoria. Si la función de distribución de  $T$  es:

$$f_T(t) = \frac{\Gamma\left(\frac{k+1}{2}\right)}{\Gamma\left(\frac{k}{2}\right) \sqrt{k\pi}} \left(1 + \frac{t^2}{k}\right)^{-\frac{k+1}{2}} \mathbb{1}_{\mathbb{R}}(t)$$

decimos que  $T \sim t_k$ . Es decir, se distribuye  $t$  con  $k$  grados de libertad.

**Teorema 22** (Propiedades de la distribución  $t$ ): Si  $T \sim t_k$ , se cumple:

1.  $\mathbb{E}(T) = 0$  si  $k > 0$
2.  $\text{Var}(T) = \frac{k}{k-2}$  si  $k > 2$
3. Si  $k = 1$ , entonces  $T \sim \text{Cauchy}(0, 1)$

**DFN 22** (Distribución  $F$ ). Decimos que  $X \sim F_{n,m}$  ( $X$  se distribuye  $F$  con  $n, m$  grados de libertad) si  $X$  tiene función de densidad

$$f_X(x) = \frac{\Gamma\left(\frac{n+m}{2}\right)}{\Gamma\left(\frac{n}{2}\right) \Gamma\left(\frac{m}{2}\right)} \left(\frac{n}{m}\right)^{\frac{n}{2}} \frac{x^{\frac{n}{2}-1}}{[1 + (n/m)x]^{(n+m)/2}}$$

**Teorema 23** (Propiedades de la distribución  $F$ ): Si  $X \sim F_{n,m}$ , se cumple:

1.  $\mathbb{E}(X) = \frac{m}{m-2}$  si  $m > 2$ .
2.  $\text{Var}(X) = \frac{2m^2(n+m-2)}{n(m-2)^2(m-4)}$  si  $m > 4$ .

**Teorema 24** (Distribuciones generadas a partir de la Normal): Sean  $X_1, \dots, X_n$  v.a.i.i.d  $\mathcal{N}(\mu, \sigma^2)$ . Entonces, se cumplen:

1.  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim \mathcal{N}(\mu, \frac{\sigma^2}{n})$ .
2. Las v.a's  $\bar{X}$  y  $\sum_{i=1}^n (X_i - \bar{X})^2$  son independientes.
3.  $J = \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma}\right)^2 \sim \chi^2_{(n-2)}$

## Estadísticas de orden

**Teorema 25:** Sean  $X_1, \dots, X_n$  v.a's independientes & idénticamente distribuidas (v.a.i.i.d), con función de distribución acumulada  $F_X(x)$  (es igual para cada  $X_i$ ). Definimos:

$$Y_1 = \min \{X_1, \dots, X_n\}$$

$$Y_j = j\text{-ésima var. más pequeña}$$

$$Y_n = \max \{X_1, \dots, X_n\}$$

La función de distribución de estas variables es:

$$F_{Y_1}(y) = 1 - [1 - F_X(y)]^n$$

$$F_{Y_j}(y) = \sum_{k=1}^n \binom{n}{k} [F_X(y)]^k [1 - F_X(y)]^{n-k}$$

$$F_{Y_n}(y) = [F_X(y)]^n$$

**Corolario 25.1:** Sean  $X_1, \dots, X_n$  v.a.i.i.d con fn. de distribución  $F_X(x)$ . La función de densidad  $f_{Y_j}(y)$  está dada por:

1.  $f_{Y_j}(y) = F_{Y_j} - \lim_{h \rightarrow 0^+} F_{Y_j}(y - h)$  si  $X_i$  son discretas.
2.  $f_{Y_j}(y) = \frac{n! f_X(y) [F_X(y)]^{j-1} [1 - F_X(y)]^{n-j}}{(j-1)!(n-j)!}$  si  $X_i$  son continuas